Corrección IX.1.5 — vista previa para revisión

Tabla 4 reformulada y costos. No es parte del manuscrito.

Tabla 4 — síntesis

ID	Conclusión original	Estado	Formulación propuesta (síntesis)
T4-01	La recuperación mejora significativamente.	Se reformula	No hay mejora uniforme: depende de estrategia y modelo. En gpt-5-mini mejoran RAG básico y Agentic; en gpt-5 solo Agentic; en nano Agentic es inferior.
T4-02	La interacción es el hallazgo principal.	Se conserva con matices	Interacción fuerte (LR = 293,28; gl = 4; p = 3,05 × 10^{-62}). No identifica un componente causal único: recuperador fijo gpt-5 y límites 7/6.
T4-03	Efecto igualador del RAG básico.	Se retira	Las diferencias se reducen, pero no desaparecen: mini−nano +0,063; gpt-5−nano +0,128; gpt-5−mini +0,065. No se demostró equivalencia.
T4-04	Sobrecarga agéntica en modelos pequeños.	Se retira como causa	41/79 salidas no sustantivas en Agentic + nano; 38/79 sustantivas con media 0,820. Modo de fallo, no degradación uniforme ni causa "agéntica".
T4-05	Validación de LLM-as-a-Judge.	Se retira "validación"	α = 0,807842/0,799542: acuerdo, no validez humana. No hay calificaciones humanas de respuestas; 23 discrepancias y 17 evaluaciones positivas no sustantivas.
T4-06	Objetivo 2 cumplido completamente.	Se reformula	Cumplimiento parcial: dos agentes activos, una delegación, sin verificador. El Agente de Calidad nunca se ejecutó.
T4-07	Agentic-RAG + mini es costo-eficiente.	Se retira y se reemplaza por Pareto	Cuesta USD 0,0564, más que RAG gpt-5 (0,0392) y Sin RAG gpt-5 (0,0478). Es no dominada, no la más barata. RAG nano: USD 0,0061 por respuesta correcta (≥ 0,75).
T4-08	Resultado transferible a otros dominios.	Se retira	Un corpus, 25 casos, una ejecución y recuperador fijo. Es una hipótesis, no transferibilidad demostrada.
T4-09	Usuarios profesionales y repositorio abierto.	Se reformula	Sin interfaz ni evaluación con usuarios. Repositorio público accesible sin login; clonación recomendada para reproducibilidad.

Costos por celda y frontera de Pareto

Celda	Costo medio	Costo total	Media corrección	Correctas ≥ 0,75	Costo por correcta	Pareto	Frec. bootstrap
Sin RAG + nano	0,0025	0,1981	0,565	26/79	0,0076	Sí	67,7%
Sin RAG + mini	0,0043	0,3395	0,325	11/79	0,0309	No	0,0%
Sin RAG + gpt-5	0,0478	3,7731	0,725	49/79	0,0770	Sí	65,7%
RAG + nano	0,0025	0,2011	0,599	33/79	**0,0061**	Sí	76,0%
RAG + mini	0,0057	0,4465	0,650	38/79	0,0117	Sí	95,0%
RAG + gpt-5	0,0392	3,0997	0,707	52/79	0,0596	Sí	94,3%
Agentic + nano	0,0447	3,5299	0,395	27/79	0,1307	No	0,0%
Agentic + mini	0,0564	4,4530	0,788	55/79	0,0810	Sí	91,9%
Agentic + gpt-5	0,0792	6,2530	0,812	56/79	0,1117	Sí	69,4%

Costos en USD, precios históricos registrados. "Correctas" usa la definición D-02: escenario fallo = 0 y puntaje promedio ≥ 0,75. La frecuencia bootstrap indica la proporción de 5.000 remuestreos por casos en que la celda permanece en la frontera. El total del experimento es USD 22,2939. La configuración con menor costo puntual por respuesta correcta es RAG básico + gpt-5-nano, con IC solapado con Sin RAG + nano; la de mayor media es Agentic-RAG + gpt-5; Agentic-RAG + gpt-5-mini es una alternativa no dominada.